



大数据导论

Introduction to Big Data



第10讲: 支持向量机

叶允明

计算机科学与技术学院


哈尔滨工业大学 (深圳)

目录

- 支持向量机的基本思想
- 线性支持向量机


支持向量机的基本思想

Support Vector Machine




- Find a linear hyperplane (decision boundary) that will separate the data


- One Possible Solution




- Another possible solution




- Many possible solutions



- Which one is better? **B1** or **B2**?
- How do you define better?




- Find hyperplane **maximizes** the margin => B1 is better than B2



More robust decision with larger margin!

Support Vector Machine



硬间隔线性支持向量机

定义

- 超平面 (hyperplane)


$$\mathbf{w}^T \mathbf{x} + b = 0$$

$\mathbf{w} = (w_1, w_2, \dots, w_n)$ 代表超平面的法向量

b 代表原点到超平面的距离

- 线性可分数据集

- 数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, $\mathbf{x}_i \in \mathbb{R}^n$, $y_i \in \{-1, 1\}$
- 存在一个超平面能将 D 中的正负样本严格地划分到两侧
- 这样的超平面称为: 分隔超平面 (separating hyperplane)



模型学习问题

对于线性可分训练数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, $\mathbf{x}_i \in \mathbb{R}^n$, $y_i \in \{-1, 1\}$

学习目标是找到一个分隔超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 使其满足:


- 正确划分所有数据:

$$\left. \begin{array}{l} \mathbf{w}^T \mathbf{x}_i + b > 0, y_i = 1 \\ \mathbf{w}^T \mathbf{x}_i + b < 0, y_i = -1 \end{array} \right\} y_i (\mathbf{w}^T \mathbf{x}_i + b) > 0$$

- 间隔 (margin) 最大:

$$\langle \mathbf{w}^*, b^* \rangle = \max_{\mathbf{w}, b} \text{margin}(\mathbf{w}, b)$$

$$\text{margin}(\mathbf{w}, b) = \min_{i=1, \dots, m} \text{distance}(\mathbf{x}_i, \langle \mathbf{w}, b \rangle)$$




点到超平面的距离

- **定理** n 维欧几里得空间中, 点 $x \in \mathbb{R}^n$ 到超平面 $w^T x + b = 0$ 的距离为:

$$d = \frac{|w^T x + b|}{\|w\|}$$

$$\|w\| = \sqrt{w_1^2 + w_2^2 + \cdots + w_n^2}$$



模型学习问题 (续)

- 对于线性可分的训练数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, $\mathbf{x}_i \in \mathbb{R}^n$, $y_i \in \{-1, 1\}$;
- 超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 的间隔可以定义为:

$$\text{margin}(\mathbf{w}, b) = \min_{i=1,2,\dots,m} \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|} = \min_{i=1,2,\dots,m} \frac{1}{\|\mathbf{w}\|} y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

原问题可改写:

$$\langle \mathbf{w}^*, b^* \rangle = \max_{\mathbf{w}, b} \text{margin}(\mathbf{w}, b) \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0$$

$$\begin{aligned} \langle \mathbf{w}^*, b^* \rangle &= \max_{\mathbf{w}, b} \min_{i=1,2,\dots,m} \frac{1}{\|\mathbf{w}\|} y_i (\mathbf{w}^T \mathbf{x}_i + b) \\ \text{s. t.} \quad &y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0, \quad i = 1, 2, \dots, m \end{aligned}$$

有约束的极值条件
拉格朗日乘子法

问题化简

原问题:

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \min_{i=1,2,\dots,m} \frac{1}{\|\mathbf{w}\|} y_i(\mathbf{w}^T \mathbf{x}_i + b) \\ \text{s. t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0, \quad i = 1, 2, \dots, m \end{aligned}$$

- 按相同比例变化 \mathbf{w} 和 b 后, 所得间隔不变, 例如 $\mathbf{w}^T \mathbf{x} + b = 0$ 和 $6\mathbf{w}^T \mathbf{x} + 6b = 0$ 是同一超平面
- 不妨设:

$$\min_{i=1,2,\dots,m} y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1$$

- 则原问题可以化简为以下有约束优化问题:

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{1}{\|\mathbf{w}\|} \\ \text{s. t.} \quad & \min_{i=1,2,\dots,m} y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1 \end{aligned}$$

问题:

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{1}{\|\mathbf{w}\|} \\ \text{s. t.} \quad & \min_{i=1,2,\dots,m} y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1 \end{aligned}$$

二次规划问题:

$$\begin{aligned} \min_{\mathbf{u}} \quad & \frac{1}{2} \mathbf{u}^T \mathbf{Q} \mathbf{u} + \mathbf{p}^T \mathbf{u} \\ \text{s. t.} \quad & \mathbf{a}_i^T \mathbf{u} \geq c_i, \quad i = 1, 2, \dots, M \end{aligned}$$

- 将条件改写:

$$\min_{i=1,2,\dots,m} y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1 \quad \longrightarrow \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m$$

问题:

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{1}{\|\mathbf{w}\|} \\ \text{s. t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

- 可进一步转化为:

$$\begin{aligned} \max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|} &\rightarrow \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \rightarrow \min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s. t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

最终可得:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s. t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

问题求解

标准问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s. t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

凸二次规划问题

$$\begin{aligned} \min_{\mathbf{u}} \quad & \frac{1}{2} \mathbf{u}^T \mathbf{Q} \mathbf{u} + \mathbf{p}^T \mathbf{u} \\ \text{s. t.} \quad & \mathbf{a}_i^T \mathbf{u} \geq c_i, \quad i = 1, 2, \dots, M \\ & \mathbf{Q} \in \mathbb{R}^{N \times N}, \mathbf{u} \in \mathbb{R}^N, \mathbf{a}_i \in \mathbb{R}^N, \mathbf{p} \in \mathbb{R}^N, c_i \in \mathbb{R} \end{aligned}$$

➤ 标准问题是标准凸二次规划问题。代入凸二次规划形式，可得：

$$\mathbf{u} = \begin{bmatrix} b \\ \mathbf{w} \end{bmatrix}; \quad \mathbf{Q} = \begin{bmatrix} \mathbf{0} & \mathbf{0}_n^T \\ \mathbf{0}_n & \mathbf{I}_{n \times n} \end{bmatrix}; \quad \mathbf{p} = \mathbf{0}_{n+1}; \quad \mathbf{a}_i^T = y_i [1 \quad \mathbf{x}_i^T]; \quad c_i = 1; \quad M = m$$

➤ 对于凸二次规划问题，可以使用如内点法、椭球法和梯度投影法等方法求解

➤ 在求出最优解 \mathbf{w}^* 和 b^* 之后，我们可以得到最终的分类决策函数为：

$$f(\mathbf{x}) = \text{sign}(\mathbf{w}^{*T} \mathbf{x} + b^*)$$

硬间隔线性支持向量机标准问题的学习算法

输入： 线性可分数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, $\mathbf{x}_i \in \mathbb{R}^n, y_i \in \{-1, 1\}$

输出： 硬间隔最大化分离超平面和分类决策函数

➤ 第一步，构造并求解约束最优化问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s. t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

➤ 第二步，返回硬间隔最大化的分隔超平面 $\mathbf{w}^{*T} \mathbf{x} + b^* = 0$ 和分类决策函数 $f(\mathbf{x}) = \text{sign}(\mathbf{w}^{*T} \mathbf{x} + b^*)$

- 从线性可分数据集当中学习到**硬间隔 (hard margin) 最大化**的分离超平面及相应分类决策函数的过程称为**硬间隔线性支持向量机**，这里的**硬间隔**是指所有数据点都可以严格分开。
- 根据间隔最大化思想，硬间隔最大化分离超平面是唯一存在的。

问题求解举例

标准问题:

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

使等号成立的点即为：
支持向量!

$$\mathbf{X} = \begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 2 & 0 \\ 3 & 0 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} +1 \\ +1 \\ -1 \\ -1 \end{bmatrix}$$




$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} (w_1^2 + w_2^2) \\ \text{s.t.} \quad & \begin{aligned} b &\geq 1 & \text{(i)} \\ 2w_1 + 2w_2 + b &\geq 1 & \text{(ii)} \\ -2w_1 - b &\geq 1 & \text{(iii)} \\ -3w_1 - b &\geq 1 & \text{(iv)} \end{aligned} \end{aligned}$$

构造有约束优化问题

$$\begin{cases} \text{(i)} + \text{(iii)} \Rightarrow w_1 \leq -1 \\ \text{(ii)} + \text{(iii)} \Rightarrow w_2 \geq +1 \end{cases} \Rightarrow \frac{1}{2} (w_1^2 + w_2^2) \geq 1$$


进一步求解可得该最优化问题的解为: $w_1 = -1, w_2 = 1, b = 1$

故硬间隔最大化分割超平面为: $-x_1 + x_2 + 1 = 0$, 可以利用函数 $\text{sign}(-x_1 + x_2 + 1)$ 来分类



存在问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s. t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$



凸二次规划问题:


- $n + 1$ 个变量 ($b \in \mathbb{R}, \mathbf{w} \in \mathbb{R}^n$)
- m 个约束条件

• 算法存在的问题

- 计算复杂度依赖于参数 \mathbf{w} 的维度，也就是特征空间的维度 n 。
- 因为特征工程或非线性映射的缘故，特征空间的维度往往非常大，特别是在特征维度大于样本数量 ($n > m$) 时，这会大大增加计算量。
- 解决方法：将原问题转换成**对偶问题**，可以让计算复杂度不依赖于特征空间维度

原问题:

- $n + 1$ 个变量
- m 个约束条件



对偶问题:

- m 个变量
- m 个约束条件

问题转换

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s. t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

利用拉格朗日乘子向量 $\lambda = [\lambda_i], \lambda_i \geq 0, i = 1, 2, \dots, m$
构建原问题的拉格朗日函数为：

$$L(\mathbf{w}, b, \lambda) = \underbrace{\frac{1}{2} \mathbf{w}^T \mathbf{w}}_{\text{优化目标}} + \sum_{i=1}^m \lambda_i \underbrace{(1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))}_{\text{约束条件}}$$

利用拉格朗日函数，原问题就等价于以下min-max问题：

$$\min_{\mathbf{w}, b} \left(\max_{\lambda: \lambda_i \geq 0} L(\mathbf{w}, b, \lambda) \right) = \min_{\mathbf{w}, b} \left(\underbrace{\infty}_{\text{不符合约束条件}}, \underbrace{\frac{1}{2} \mathbf{w}^T \mathbf{w}}_{\text{符合约束条件}} \right) = \min_{\mathbf{w}, b} \underbrace{\frac{1}{2} \mathbf{w}^T \mathbf{w}}_{\text{符合约束条件}}$$

在 (\mathbf{w}, b) 给定的情况下，对于任何 $\lambda: \lambda_i \geq 0$ ，都有

$$\max_{\lambda: \lambda_i \geq 0} L(\mathbf{w}, b, \lambda) \geq L(\mathbf{w}, b, \lambda)$$

故对于任何 $\mathbf{w}, b, \lambda: \lambda_i \geq 0$ ，都有

$$\min_{\mathbf{w}, b} \left(\max_{\lambda: \lambda_i \geq 0} L(\mathbf{w}, b, \lambda) \right) \geq \min_{\mathbf{w}, b} L(\mathbf{w}, b, \lambda)$$

$$\min_{\mathbf{w}, b} \left(\max_{\lambda: \lambda_i \geq 0} L(\mathbf{w}, b, \lambda) \right) \geq \max_{\lambda: \lambda_i \geq 0} \left(\min_{\mathbf{w}, b} L(\mathbf{w}, b, \lambda) \right)$$

拉格朗日对偶问题

- 设原问题的最优值为 p^* ，对偶问题的最优值为 d^*

➤ 若 $p^* \geq d^*$ ，则两个问题的关系是弱对偶性

➤ 若 $p^* = d^*$ ，则两个问题的关系是强对偶性

- 若原问题满足以下条件（Slater条件），则原问题与对偶问题有强对偶性

✓ 原问题是凸问题

✓ 原问题有解

✓ 原问题的约束条件是线性约束条件

$$\min_{\mathbf{w}, b} \left(\max_{\lambda: \lambda_i \geq 0} \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) \right)$$

- SVM原问题满足上述条件，故 $p^* = d^*$ ，对偶问题的解就是原问题的解，我们解决对偶问题即可

对偶问题简化

$$\max_{\lambda: \lambda_i \geq 0} \left(\min_{\mathbf{w}, b} \left[\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) \right] \right) \quad L(\mathbf{w}, b, \lambda)$$

- (\mathbf{w}, b) 要满足 $L(\mathbf{w}, b, \lambda)$ 最小，则对应梯度应为0，即：

➤ $\frac{\partial L(\mathbf{w}, b, \lambda)}{\partial b} = 0 = -\sum_{i=1}^m \lambda_i y_i$ ，我们将 $\sum_{i=1}^m \lambda_i y_i = 0$ 加到对偶问题的条件中不会影响问题的最优解，故

$$\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0} \left(\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i)) - \sum_{i=1}^m \lambda_i y_i \cdot b \right)$$

➡ $\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0} \left(\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i)) \right)$

➤ $\frac{\partial L(\mathbf{w}, b, \lambda)}{\partial \mathbf{w}} = \mathbf{0} = \mathbf{w} - \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i$ ，同样将 $\mathbf{w} = \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i$ 加到对偶问题的条件中，

$$\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0; \mathbf{w} = \sum \lambda_i y_i \mathbf{x}_i} \left(\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i)) \right)$$

➡ $\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0; \mathbf{w} = \sum \lambda_i y_i \mathbf{x}_i} \left(\min_{\mathbf{w}, b} \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \lambda_i - \mathbf{w}^T \mathbf{w} \right)$

展开

$$\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0; \mathbf{w} = \sum \lambda_i y_i \mathbf{x}_i} \left(\min_{\mathbf{w}, b} -\frac{1}{2} \left\| \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i \right\|^2 + \sum_{i=1}^m \lambda_i \right)$$

➡ $\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0; \mathbf{w} = \sum \lambda_i y_i \mathbf{x}_i} -\frac{1}{2} \left\| \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i \right\|^2 + \sum_{i=1}^m \lambda_i$

与 \mathbf{w}, b 无关，可以去掉最小化

最终需求解的对偶问题

KKT条件

$$\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0; \mathbf{w} = \sum \lambda_i y_i \mathbf{x}_i} -\frac{1}{2} \left\| \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i \right\|^2 + \sum_{i=1}^m \lambda_i$$

总结一下, (\mathbf{w}, b, λ) 是原问题与对偶问题最优解的充要条件是 (\mathbf{w}, b, λ) 满足下面的Karush-Kuhn-Tucker (KKT) 条件:

- 满足原问题的约束条件: $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m$
- 满足对偶问题约束条件: $\lambda_i \geq 0$
- 满足对偶问题优化条件:

➤ $\frac{\partial L(\mathbf{w}, b, \lambda)}{\partial b} = 0 = -\sum_{i=1}^m \lambda_i y_i$, 即 $\sum_{i=1}^m \lambda_i y_i = 0$

➤ $\frac{\partial L(\mathbf{w}, b, \lambda)}{\partial \mathbf{w}} = \mathbf{0} = \mathbf{w} - \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i$, 即 $\mathbf{w} = \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i$

- 满足原问题的优化条件: 将原问题转换成 minmax 问题时, $\lambda_i (1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) = 0$

对偶互补条件

求解对偶问题

$$\max_{\lambda: \lambda_i \geq 0; \sum \lambda_i y_i = 0; \mathbf{w} = \sum \lambda_i y_i \mathbf{x}_i} -\frac{1}{2} \left\| \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i \right\|^2 + \sum_{i=1}^m \lambda_i$$

改写上述问题：最大化转换为最小化（取负号）

$$\min_{\lambda} \frac{1}{2} \left\| \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i \right\|^2 - \sum_{i=1}^m \lambda_i$$

展开

$$\min_{\lambda} \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \lambda_i \lambda_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^m \lambda_i$$

s. t.

$$\sum_{i=1}^m \lambda_i y_i = 0$$

$$\lambda_i \geq 0, \quad i = 1, 2, \dots, m$$

➤ 代入凸二次规划形式，可得：

$$\begin{aligned} & \sum_{i=1}^m \lambda_i y_i \geq 0 \\ & -\sum_{i=1}^m \lambda_i y_i \geq 0 \end{aligned} \longrightarrow \mathbf{a}_{\geq} = \mathbf{y} = [y_i]_m; c_{\geq} = 0; \mathbf{a}_{\leq} = -\mathbf{y}; c_{\leq} = 0; \mathbf{a}_i = \mathbf{e}_i; c_i = 0;$$

$\mathbf{e}_i \in \mathbb{R}^m$ 是第 i 行为 1 的单位向量

➤ 由于 \mathbf{Q} 可能比较大，实际应用中需利用专为 SVM 设计的方法解上述问题，得最优解 λ

求解对偶问题

- 在求得最优解 $\lambda^* = [\lambda_i^*]$ 后
- 可以利用KKT条件求得原问题的最优解 \mathbf{w}^* 和 b^*

➤ $\mathbf{w}^* = \sum_{i=1}^m \lambda_i^* y_i \mathbf{x}_i$

- 利用对偶互补条件，如果某个 j 使得 $\lambda_j^* > 0$ ，则 $1 - y_j(\mathbf{w}^{*T} \mathbf{x}_j + b) = 0$ ，左右两边乘以 y_j 后可得：

当有多个 $\lambda_j^* > 0$ 时，
算得的 b 可能不一样

$$b^* = y_j - \mathbf{w}^{*T} \mathbf{x}_j$$

- 最后我们可以得到最终的分类决策函数的对偶形式为


$$f(x) = \text{sign}(\mathbf{w}^{*T} \mathbf{x} + b^*)$$

- 支持向量

- 对偶问题的解 $\lambda^* = [\lambda_i^*](i = 1, 2, \dots, n)$ 中对应于分量 $\lambda_i^* \neq 0$ 的样本点 (\mathbf{x}_i, y_i) 的实例 \mathbf{x}_i 称为**支持向量**。
- 线性支持向量机中，支持向量可理解为经过间隔边界上的样本点，其作为向量支持着分类界限，决定决策超平面的参数取值。

(KKT) 条件:

- $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m$
- $\lambda_i \geq 0$
- $\sum_{i=1}^m \lambda_i y_i = 0; \mathbf{w} = \sum_{i=1}^m \lambda_i y_i \mathbf{x}_i$
- $\lambda_i (1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) = 0$ (对偶互补条件)



硬间隔线性SVM对偶问题的学习算法

输入： 线性可分数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}, \mathbf{x}_i \in \mathbb{R}^n, y_i \in \{-1, 1\}$

输出： 硬间隔最大化分离超平面和分类决策函数

➤ 第一步，构造带约束的凸二次规划问题，并求解得到最优解 $\lambda^* = [\lambda_i^*](i = 1, 2, \dots, m)$

$$\begin{aligned} \min_{\lambda} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \lambda_i \lambda_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^m \lambda_i \\ \text{s. t.} \quad & \sum_{i=1}^m \lambda_i y_i = 0 \\ & \lambda_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

➤ 第二步，计算对偶问题对应的最优解 \mathbf{w}^* ，并任意选择 λ^* 的一个正分量 $\lambda_j^* > 0$ ，以求解 b^*

$$\mathbf{w}^* = \sum_{i=1}^m \lambda_i^* y_i \mathbf{x}_i$$

$$b^* = y_j - \mathbf{w}^{*T} \mathbf{x}_j$$

➤ 第三步，返回硬间隔最大化分离超平面 $\mathbf{w}^{*T} \mathbf{x} + b^* = 0$ 和分类决策函数 $f(\mathbf{x}) = \text{sign}(\mathbf{w}^{*T} \mathbf{x} + b^*)$

有监督学习的一些问题


混淆矩阵

- 给定m类, 混淆矩阵中的每一个表目 CM_{ij} 表示类i的元组被分类器标记为类j的个数

classes	buy_computer=yes	buy_computer=no	total	recognition(%)
buy_computer=yes	6954	46	7000	99.34
buy_computer=no	412	2588	3000	86.27
total	7366	2634	10000	95.52

真实类别	预测类别	
	C1	C2
	C1	C2
	true positives	false negatives
	false positives	true negatives

交叉验证




训练数据的合理利用

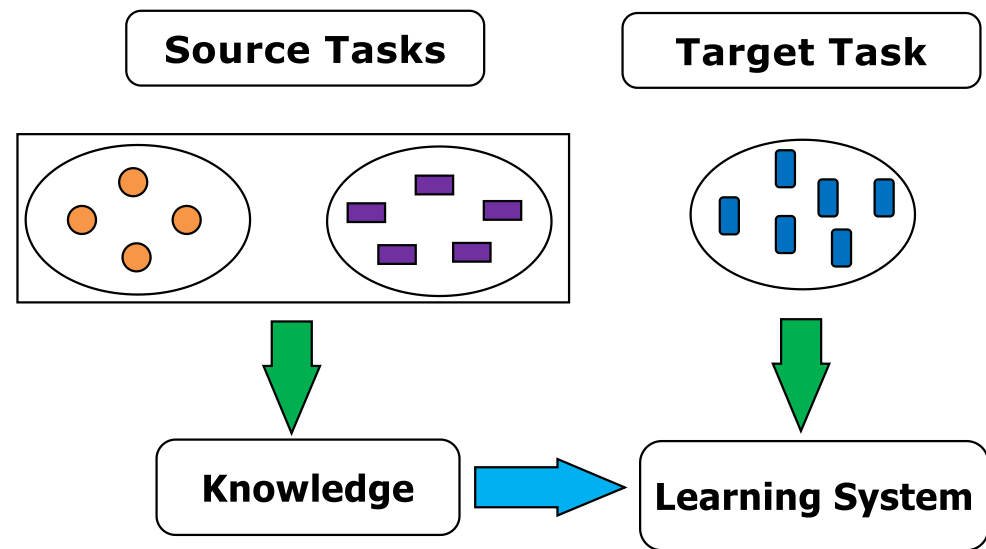
- 训练集-验证集-测试集
- 尽量少 “测试”

迁移学习：概念框架

- **迁移学习目标：** 从一个或多个源任务提取知识，并将这种知识用于目标任务
- **传统学习方法：** 为每个新任务建立新的分类器
- **迁移学习方法：** 为新任务构建分类器时，使用源任务的知识



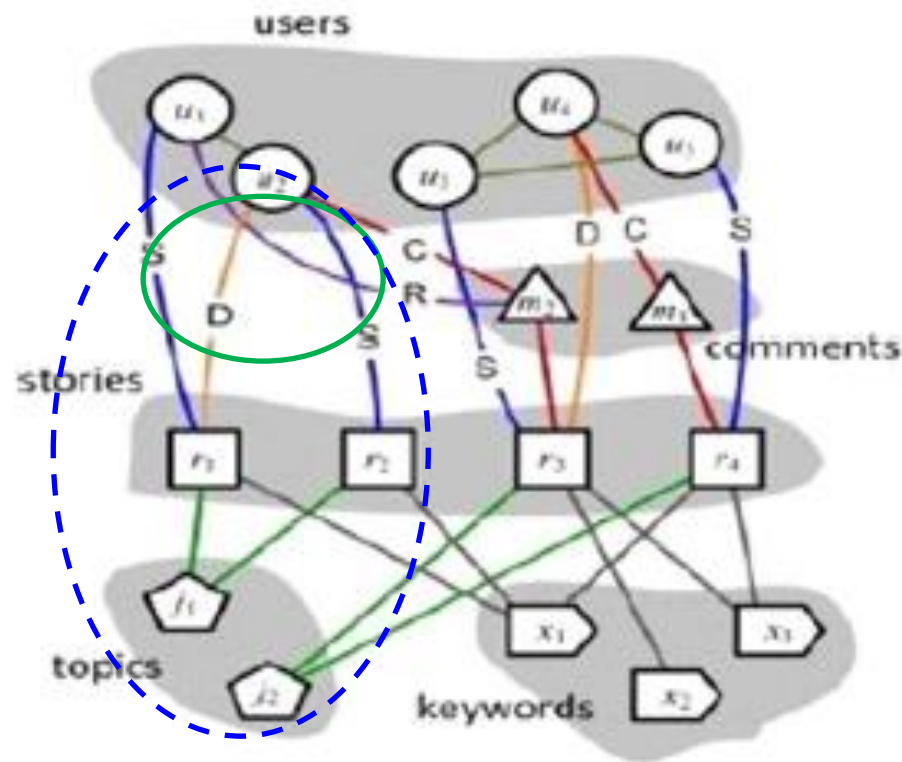
传统学习框架



迁移学习框架

其他热门研究课题

- 社交网络/关系图的分类
- 多类标分类
- 多元实例学习
- 深度学习
-



陈宝林著. 最优化理论与算法 (第二版) .
清华大学出版社, 2005.

